華東師範大學
East China Normal University

（酒店预定需求分析&取消率预测）

姓　　名：杨茜雅

学　　号：10215501435

学　　院：数据科学与工程学院

课　　程：数据科学与工程导论

–

2023 年 1 月

目录

1、 实验引言

1.1 背景介绍

大数据时代，企业比以往任何时候都更加依赖数据分析用于优化和分析整体性能。数据分析提供了管理、保护、转换和交流信息的解决方案，以做出更有根据的决策。通过利用原始数据，业务数据分析生成可用和可理解的数据，企业利用这些数据来降低风险和成本，并提高盈利能力。本次项目运用到数据分析需要的关键技术之一——机器学习，作为人工智能的一个方面之一它允许软件发现并自动化业务模型，在本次酒店预定需求分析和取消率预测的项目中尽快归档并根据模型预测客人是否会取消订单。数据分析使酒店等服务场所可以使用数据来识别客人趋势并且更详细地了解客户需求，了解内部弱点，并创建各种解决方案来对标这些问题，提高整体盈利能力和客户口碑。

在疫情放开的当下，相信在不久的将来许多人会把因为疫情而推迟的旅行计划重新提上日程。提到旅行就不得不牵扯到酒店的预订，在旅游业因为疫情防控低迷了几年以后，酒店的订单量会因为人们增加的出游计划而有所回升。在订单量暴涨的情况下，分析顾客行为数据就显得更为重要。

1.2 数据集简介

项目基于 kaggle 网站上名为 Hotel booking demand 的数据集进行研究，网 址 https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand。数据集包含了从 2015 年 7 月到 2017 年 8 月一家城市酒店和一家度假酒店的预定信息、包括诸如预定时间、逗留时间、成人、儿童、婴儿的数量，以及可用的停车位数量等 32 条信息。

```
Data columns (total 32 columns):
 #   Column                          Non-Null Count   Dtype
---  ------                          --------------   -----
 0   hotel                           119390 non-null  object
 1   is_canceled                     119390 non-null  int64
 2   lead_time                       119390 non-null  int64
 3   arrival_date_year               119390 non-null  int64
 4   arrival_date_month              119390 non-null  object
 5   arrival_date_week_number        119390 non-null  int64
 6   arrival_date_day_of_month       119390 non-null  int64
 7   stays_in_weekend_nights         119390 non-null  int64
 8   stays_in_week_nights            119390 non-null  int64
 9   adults                          119390 non-null  int64
 10  children                        119386 non-null  float64
 11  babies                          119390 non-null  int64
 12  meal                            119390 non-null  object
 13  country                         118902 non-null  object
 14  market_segment                  119390 non-null  object
 15  distribution_channel            119390 non-null  object
 16  is_repeated_guest               119390 non-null  int64
 17  previous_cancellations          119390 non-null  int64
 18  previous_bookings_not_canceled  119390 non-null  int64
 19  reserved_room_type              119390 non-null  object
 20  assigned_room_type              119390 non-null  object
 21  booking_changes                 119390 non-null  int64
 22  deposit_type                    119390 non-null  object
 23  agent                           103050 non-null  float64
 24  company                         6797 non-null    float64
 25  days_in_waiting_list            119390 non-null  int64
 26  customer_type                   119390 non-null  object
 27  adr                             119390 non-null  float64
 28  required_car_parking_spaces     119390 non-null  int64
 29  total_of_special_requests       119390 non-null  int64
 30  reservation_status              119390 non-null  object
 31  reservation_status_date         119390 non-null  object
dtypes: float64(4), int64(16), object(12)
```

2、 问题描述

该项目中我首先对现有数据做了一些预处理，方便后续工作，再从总体概况、顾客背景、酒店经营状况、顾客行为、取消率和相关性分析的角度进行探索性分析。最后建立多个机器学习的模型来预测顾客是否会取消订单，并且针对表现最好的 base model 进行优化和特征评分。

3、 实验过程

3.1 数据预处理

```
print(data.isnull().sum()[data.isnull().sum() != 0])
```

```
children        4
country       488
agent       16340
company    112593
```

通过查看缺失值可以发现 company 特征缺失过多，所以删去。对于缺失值较少的 country 和 children，用字段内的众数填充。对于 agent，则用 0 填充，表示没有指定任何机构。

```
# 缺失值处理
# company 缺失太多，删除
# country、children和agent缺失比较少，用字段内的众数填充
# country和children用字段内的众数填充 agent缺失值用0填充，代表没有指定任何机构
data_new = data.copy(deep=True)
data_new.drop("company", axis=1, inplace=True)
data_new["agent"].fillna(0, inplace=True)
data_new["children"].fillna(data_new["children"].mode()[0], inplace=True)
data_new["country"].fillna(data_new["country"].mode()[0], inplace=True)
```

同时对于异常数据进行删除，比如 adults+children+babies=0 的订单是不符合常理的，理应删除。对于用到简写的字段需要进行字段映射处理，增加可读性。最后形成新的数据集 data_new，规模从（119390，32）变为（87204，31）。

```
# 处理一下异常值：成人+小孩+婴儿=0的情况都需要删掉
data_new["children"] = data_new["children"].astype(int)
data_new["agent"] = data_new["agent"].astype(int)  # 转换数据类型
zero_guests = list(data_new["adults"] + data_new["children"] + data_new["babies"] == 0)
data_new.drop(data_new.index[zero_guests], inplace=True)
# meal字段映射处理
data_new["meal"].replace(["Undefined", "BB", "FB", "HB", "SC"],["No Meal", "Breakfast", "Full Board", "Half Board", "No Meal"], inplace=True)
# 数据去重
data_new.drop_duplicates(inplace=True)
data_new.to_csv('data_new.csv')
```

3.2 探索性分析

3.2.1 总体概况（不同酒店的总预定量&&取消量&&年度订单走势）

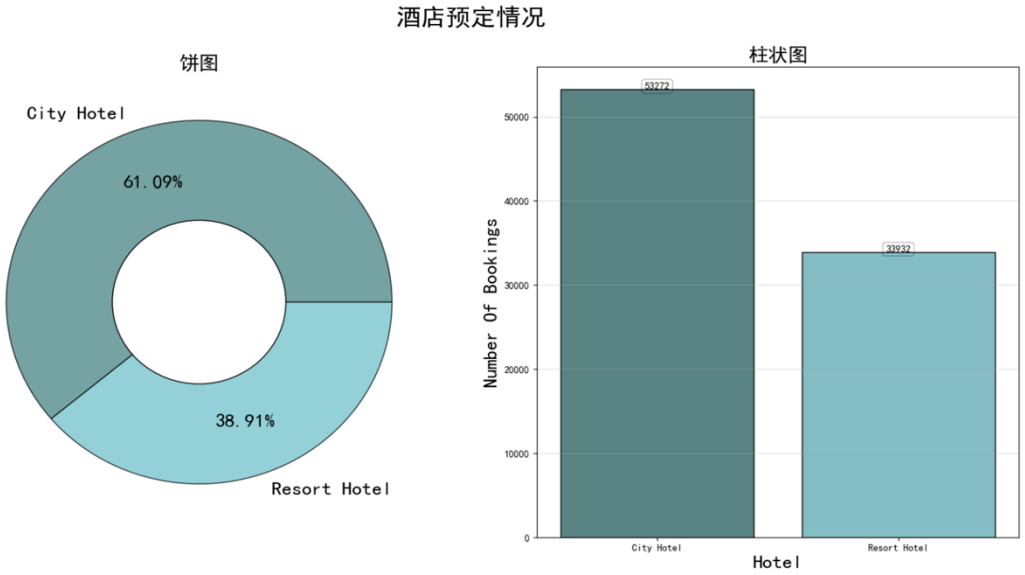

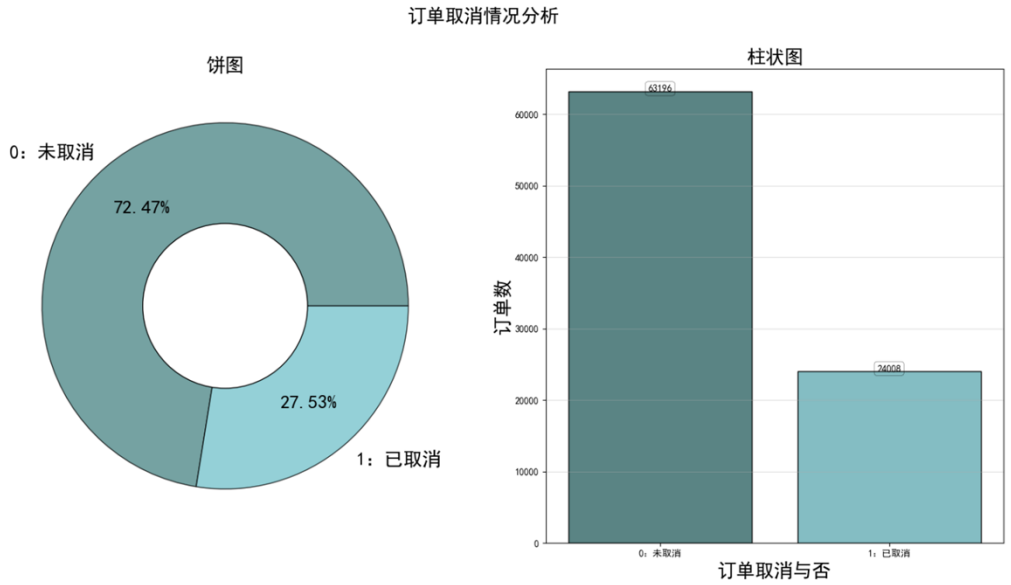

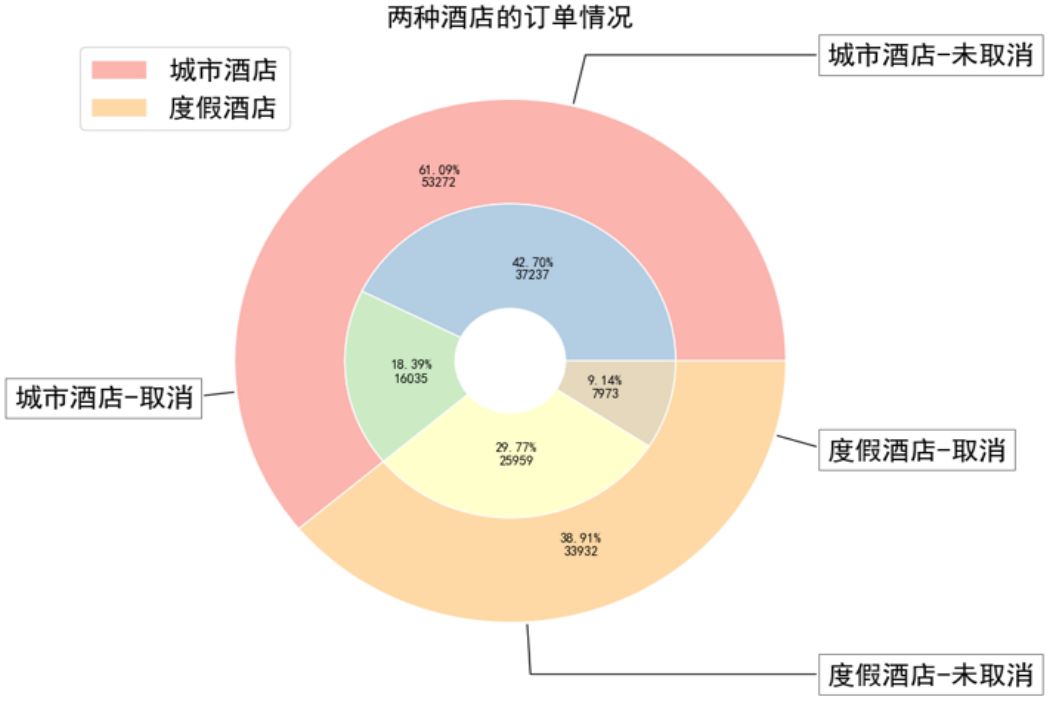
两种酒店的订单情况
城市酒店
度假酒店
城市酒店-未取消
61.09%
53272
42.70%
37237
18.39%
16035
9.14%
7973
29.77%
25959
38.91%
33932
城市酒店-取消
度假酒店-取消
度假酒店-未取消

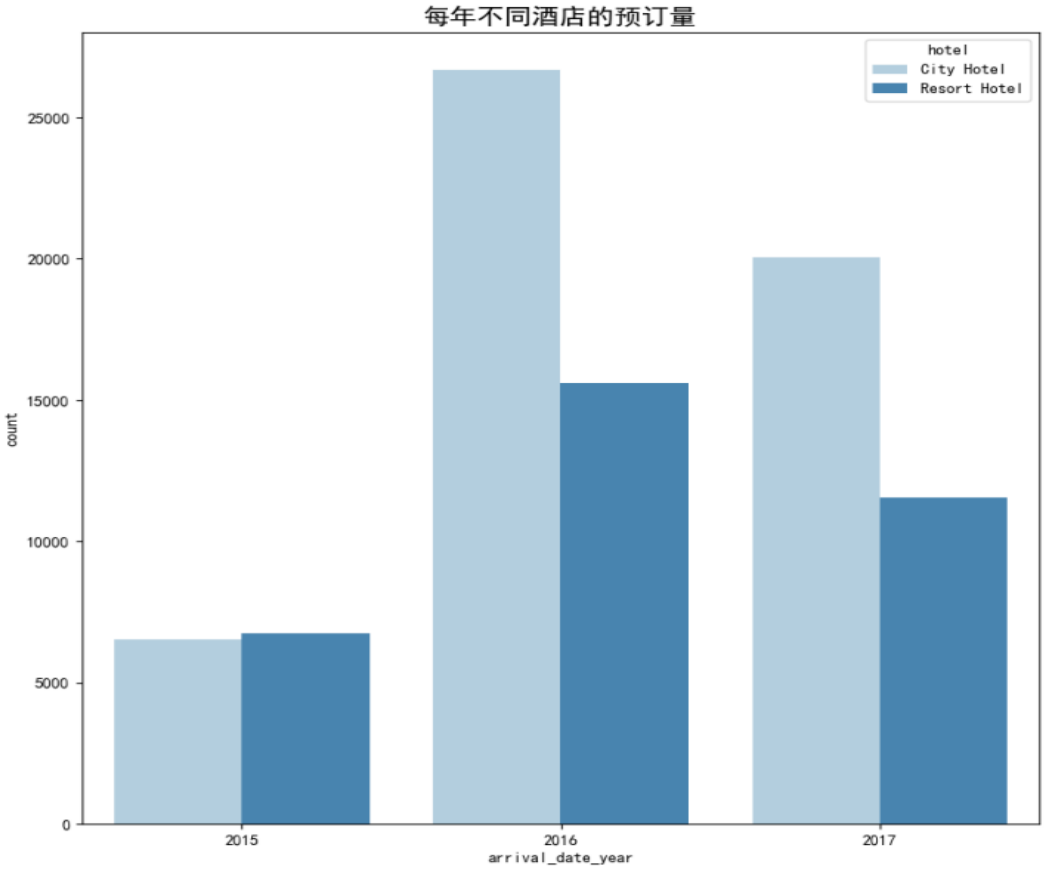
每年不同酒店的预订量
hotel
City Hotel
Resort Hotel
25000
20000
15000
10000
5000
0
count
2015
2016
2017
arrival_date_year

结论：

城市酒店就取消量和预订量而言都高于度假酒店，年度订单量走势2016>2017>2015，订单取消和未取消比约为 3：7，数据集存在样本不均衡的问题。

3.2.2 顾客背景（新老顾客分布&&取消率&&顾客地域分布）

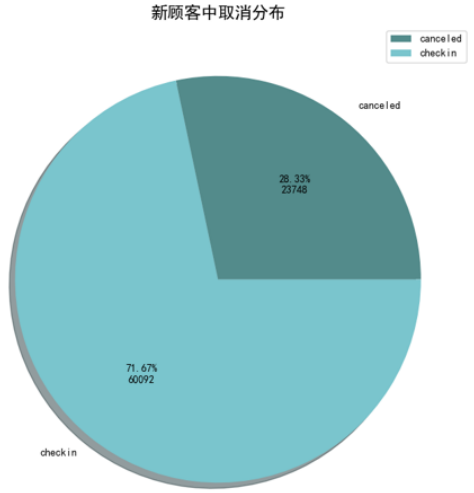

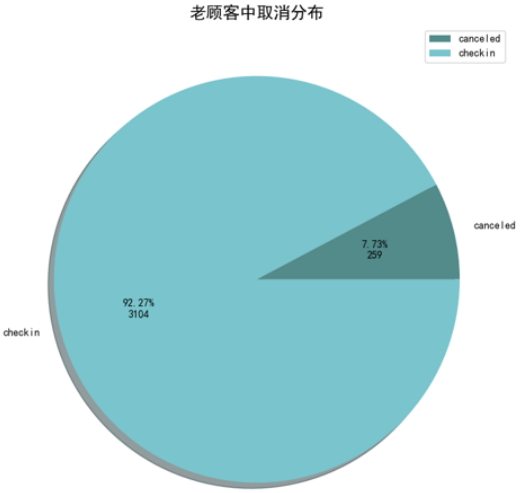

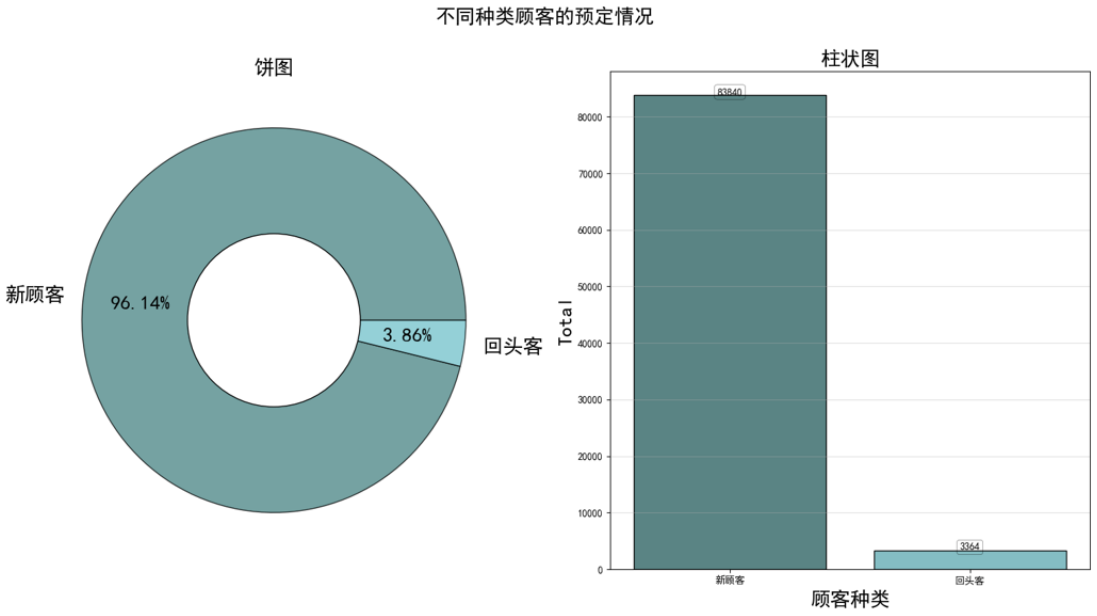

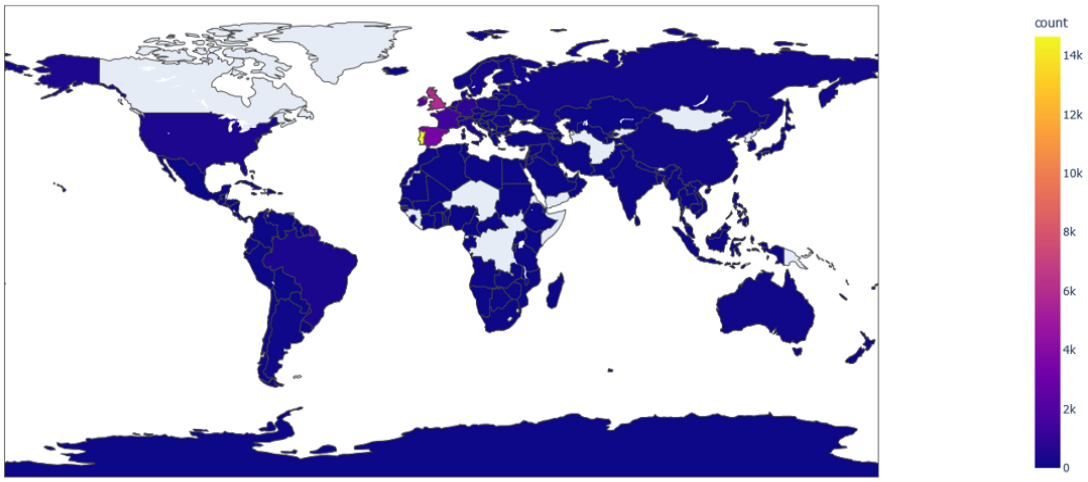

结论：

老顾客几乎没有，所以就取消率而言也是新顾客>老顾客，地域分布情况而言顾客主要集中在葡萄牙、英国、法国、西班牙、德国等西欧地区。

3.2.3 酒店经营状况（每月不同酒店的平均旅客数&&预订量和取消率&&人均价格）

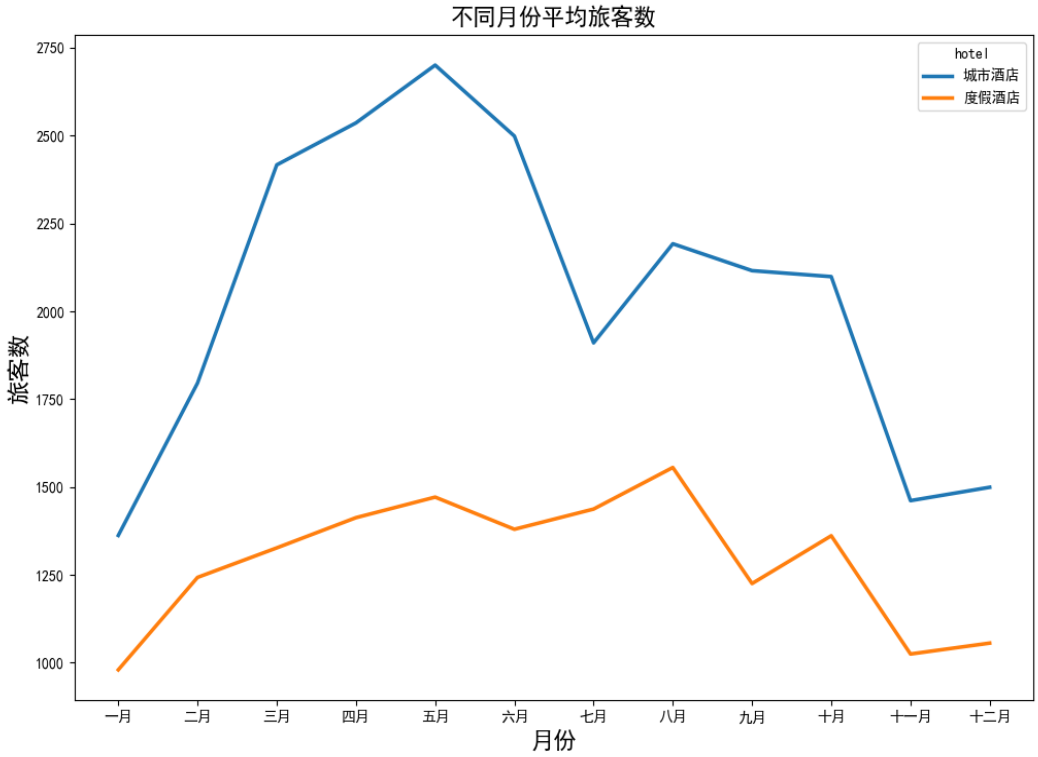

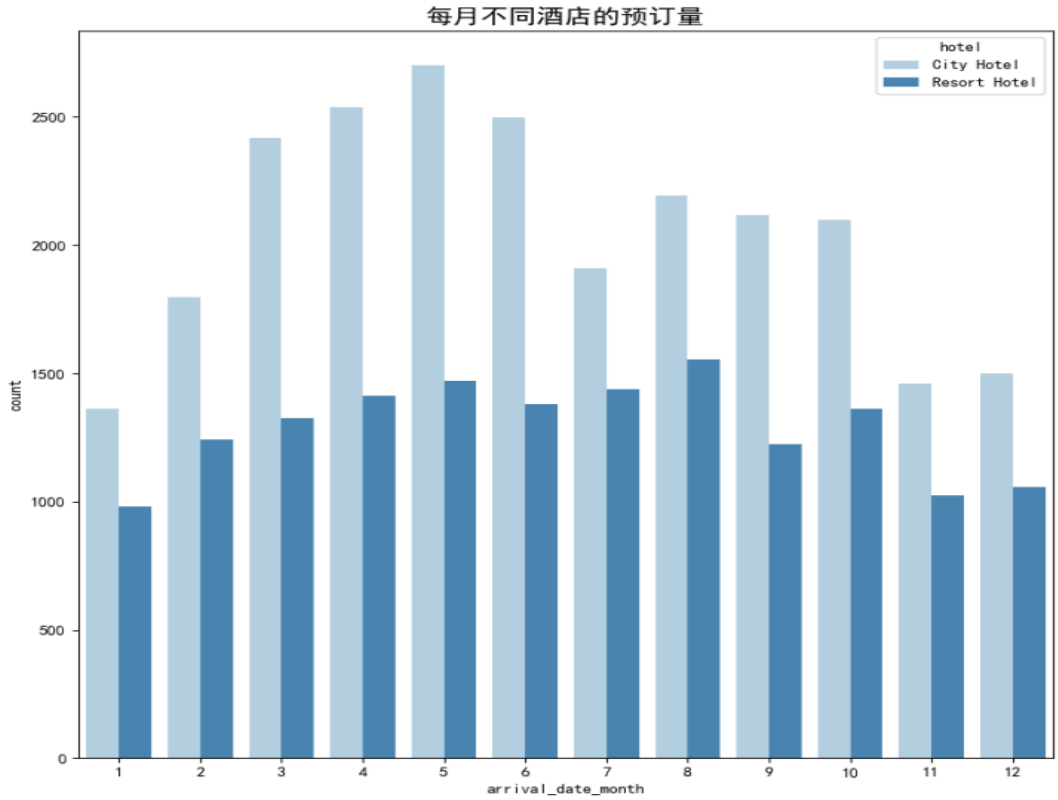

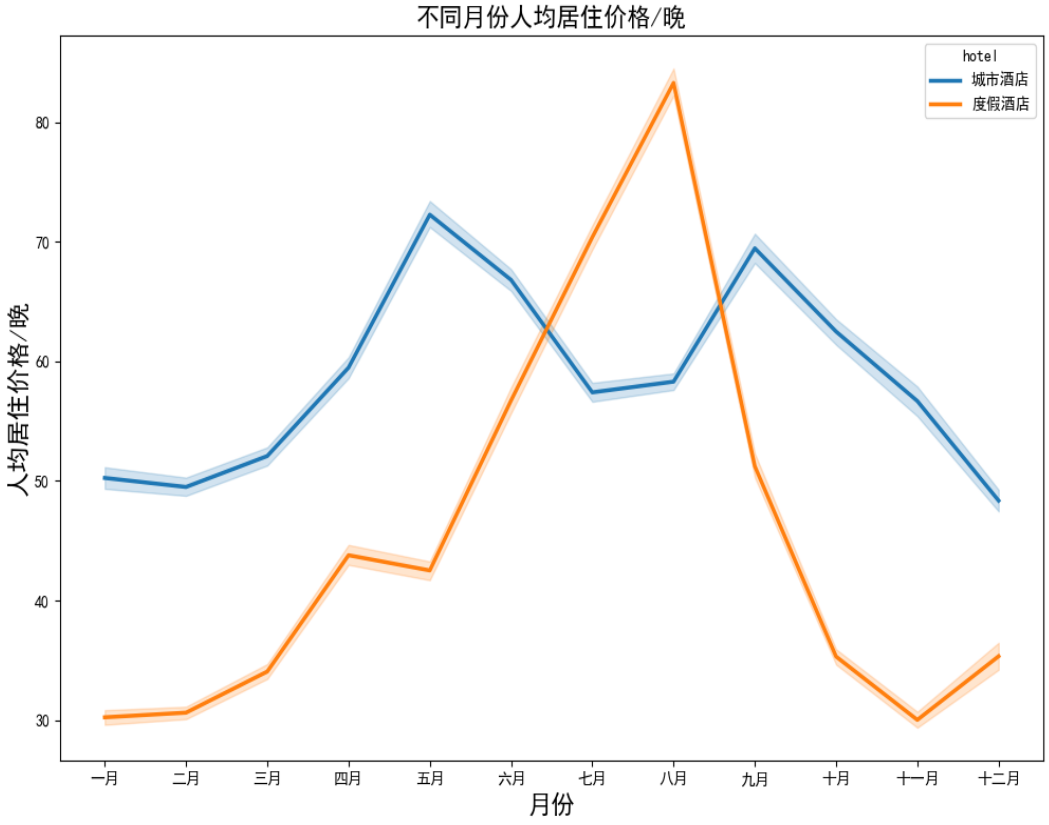

旅客数和订单量的走势是大致相同的，此处选取订单量而不是人均价格作为衡量旅游淡旺季的指标。可以看出城市酒店在 3-5 月（春季）和 8-10 月（秋季）

为预定旺季，房价也相应提高,订单数和总客流量也迎来峰值；度假酒店 3-5 月份（春季）和 7-9 月份（秋季）为预定旺季，房价稍有上浮。

度假酒店在 7-8 月房价很高，远高于其他月份，不排除有夏季人们扎堆出游的影响。两种酒店冬季生意都不太好。度假酒店全年订单量比较稳定。

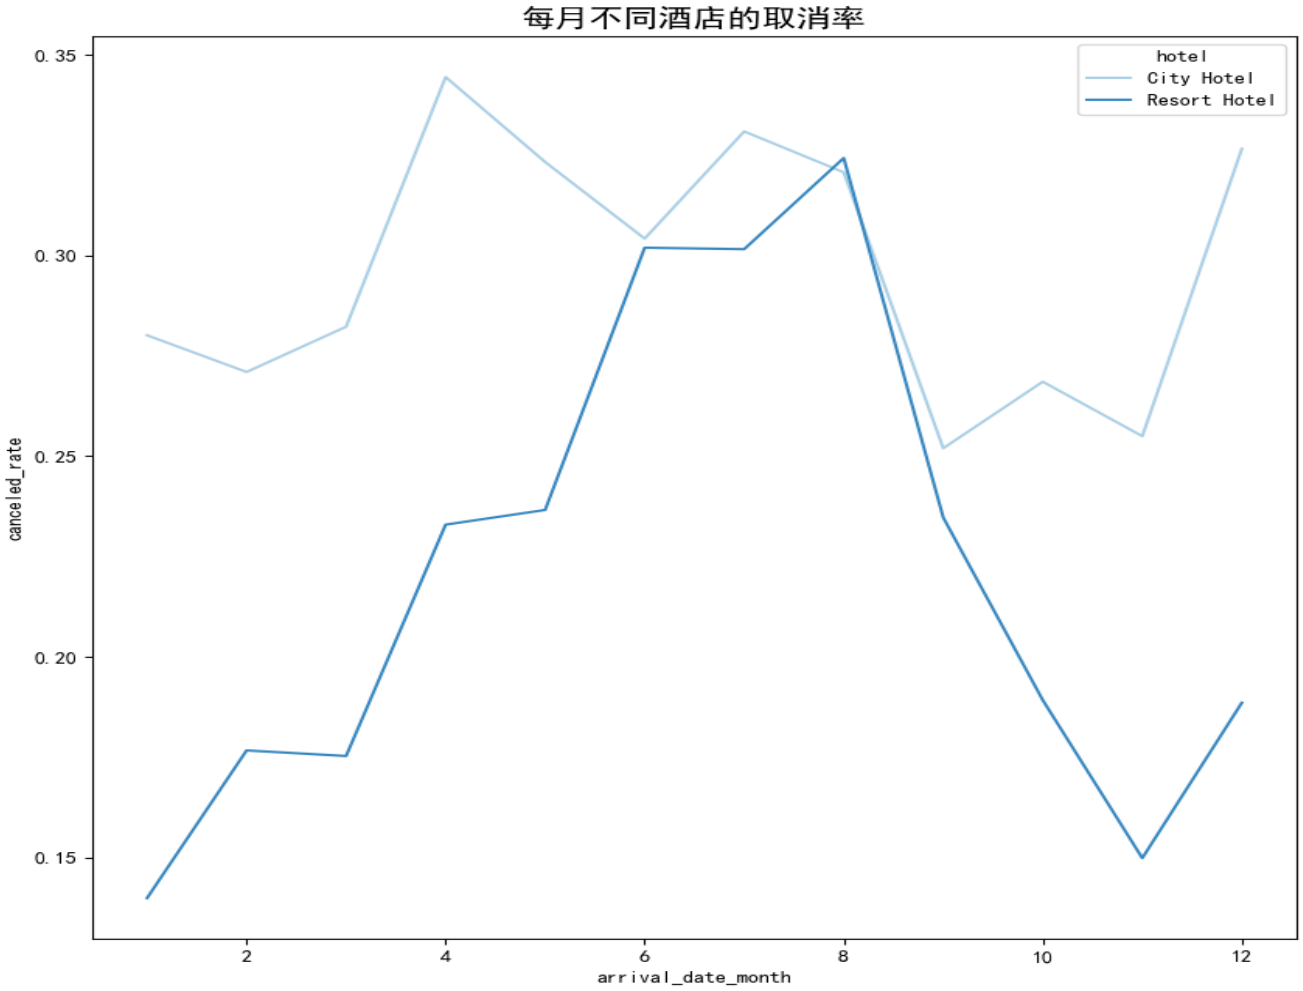

但是就取消率而言，度假酒店就没有这么稳定了，全年起伏大，过年期间取消率极低，原因分析：1、冬季订单少。2、跨年旅游，不容易临时取消。

城市酒店取消率几乎全年都高于度假酒店，4 月和 7-8 月和冬季取消率都偏高。

3.2.4 顾客行为

3.2.4.1 天数选择

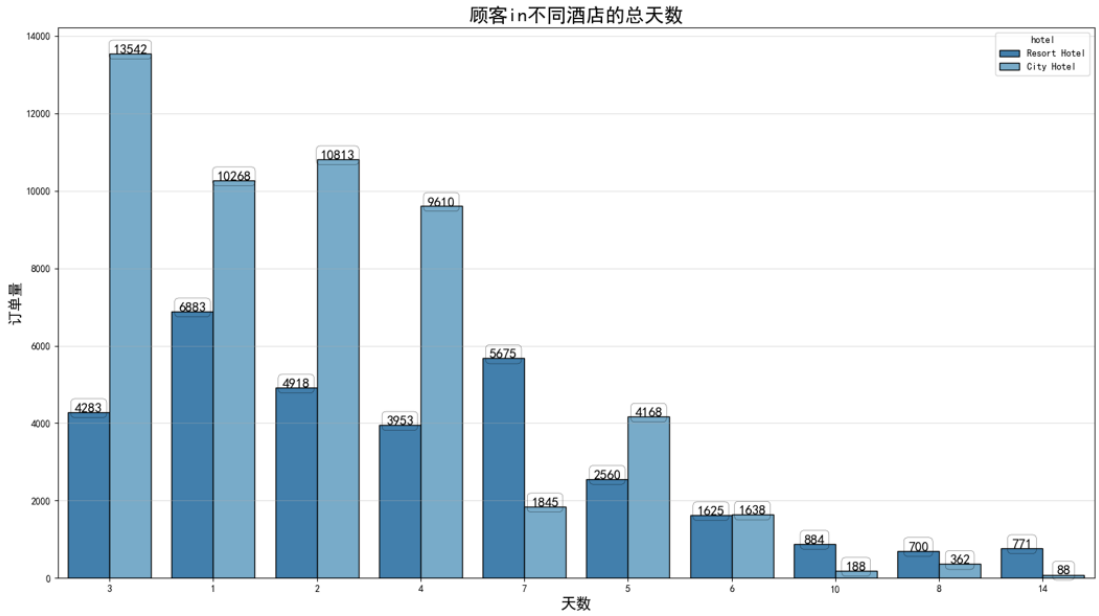

度假酒店最受欢迎的住宿时间是一晚、七晚、两晚、三晚和四晚；城市酒店最受欢迎的住宿时间是三晚、两晚、一晚和四晚。

可以看出人们居住时间越长，越倾向于选择度假酒店。

3.2.4.2 特殊要求

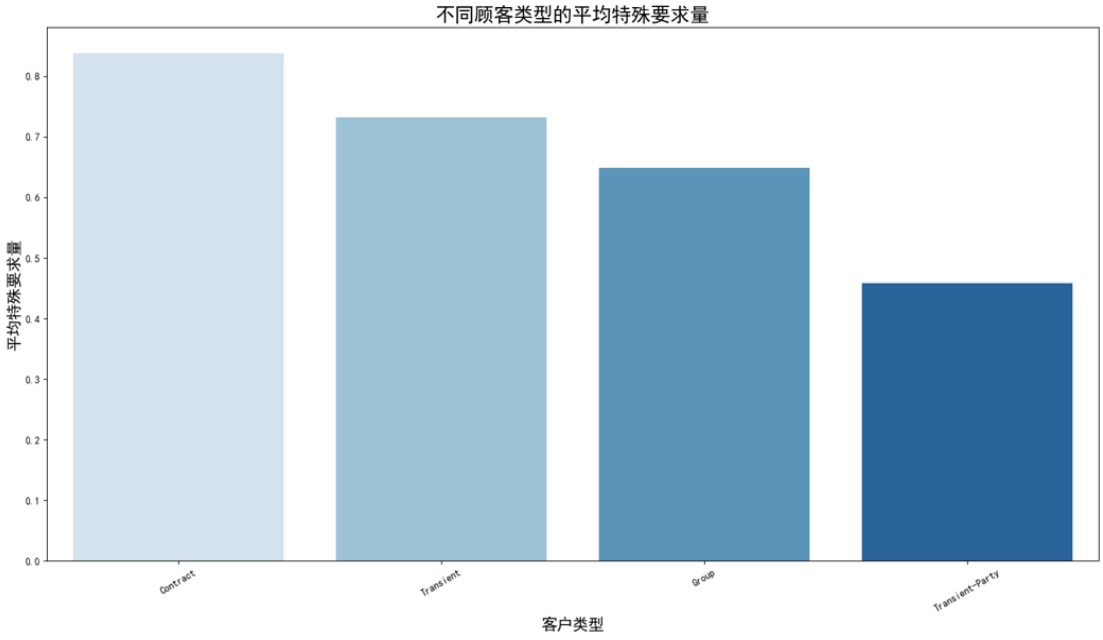

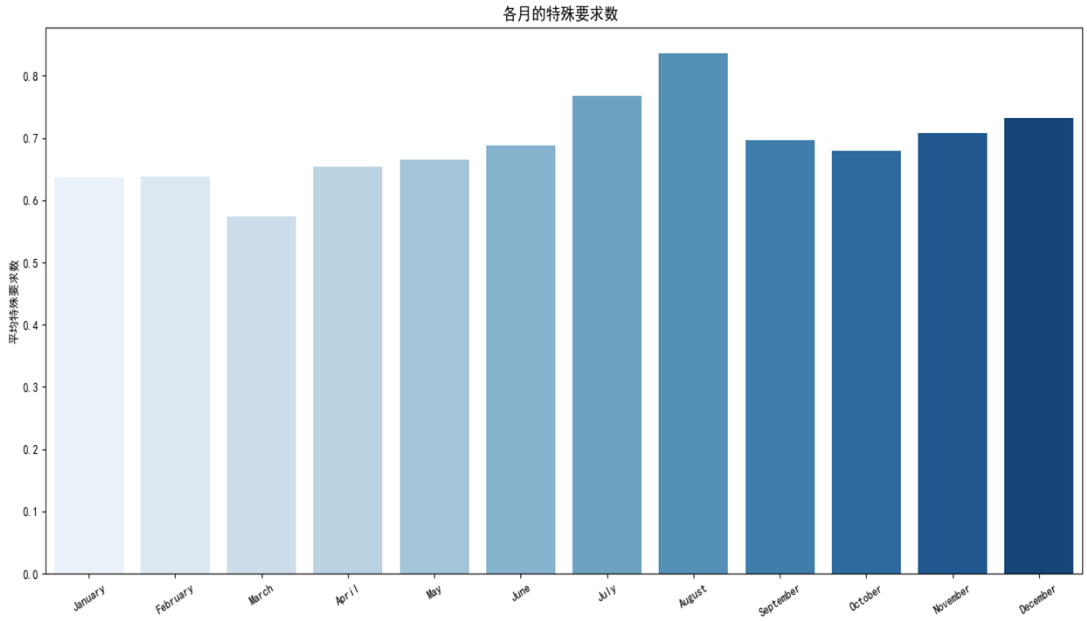

跟团客人的特殊要求数量最多，临时派对客人的特殊要求数量最少。7、8 和 12 月份这种旅游旺季或者有特殊节日意义的月份，特殊要求多一些。

3.2.5 取消率

3.2.5.1 渠道选择

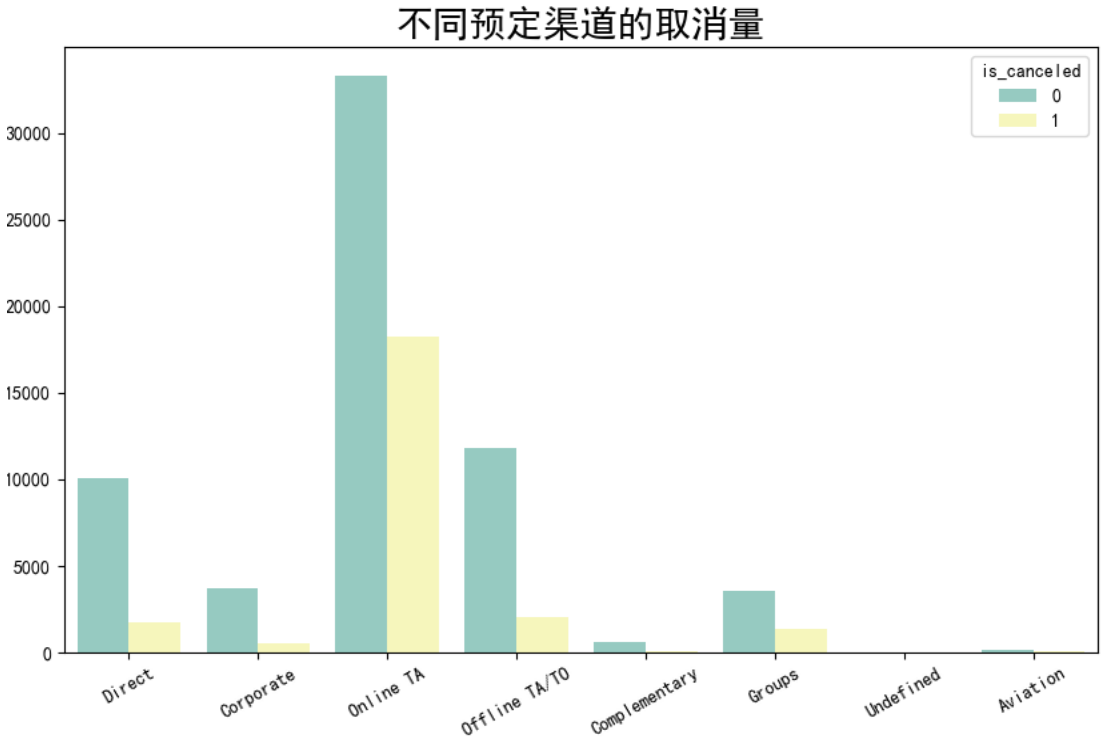

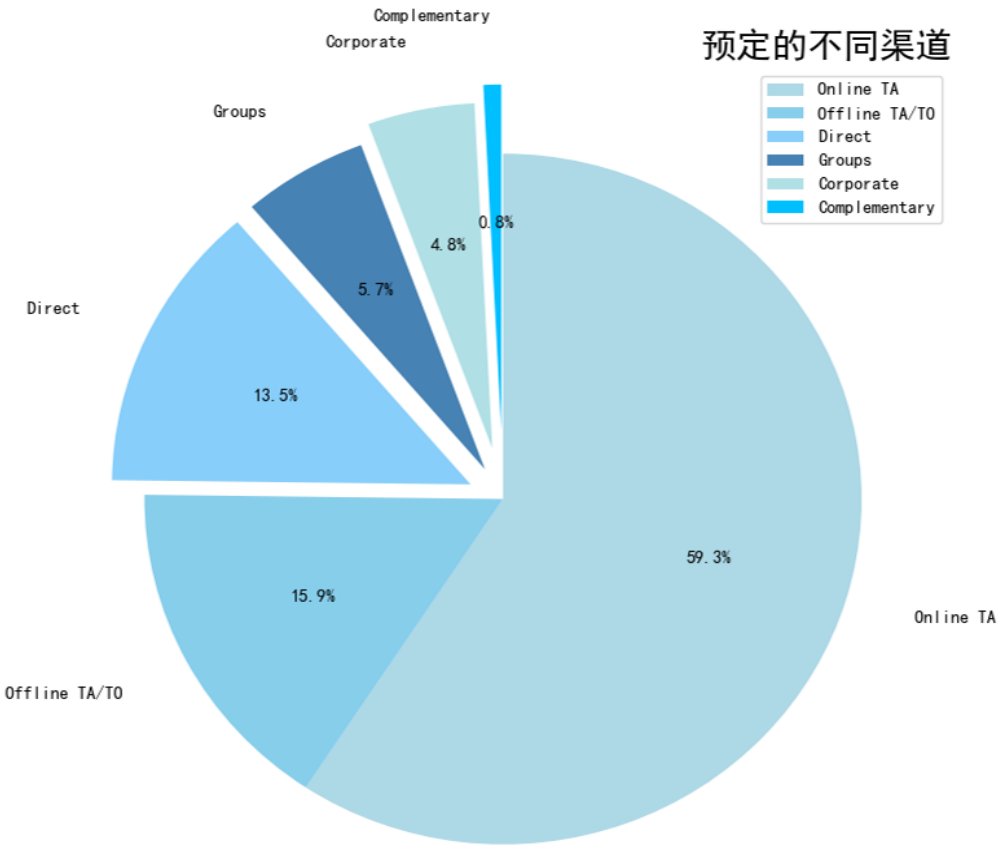

就预定而言，不管是线上还是线下，旅行社都是人们的首选，总体站 50%以上。

就取消而言，线上 TA 比例最高，其次是线下 TA/TO，最后是团体预定。

3.2.5.2 历史取消订单量

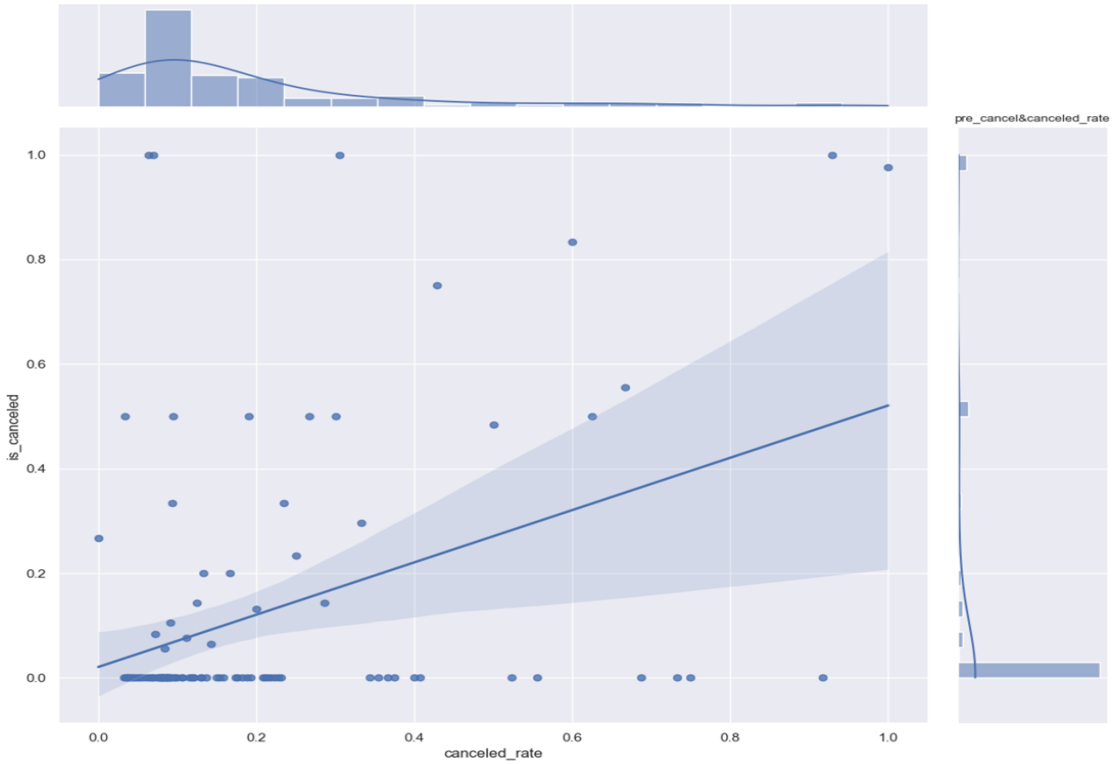

由散点图和拟合的曲线可以看出顾客在此次订单之前，取消过的订单越多，越有可能取消本次订单。

3.2.5.3 提前预定时长

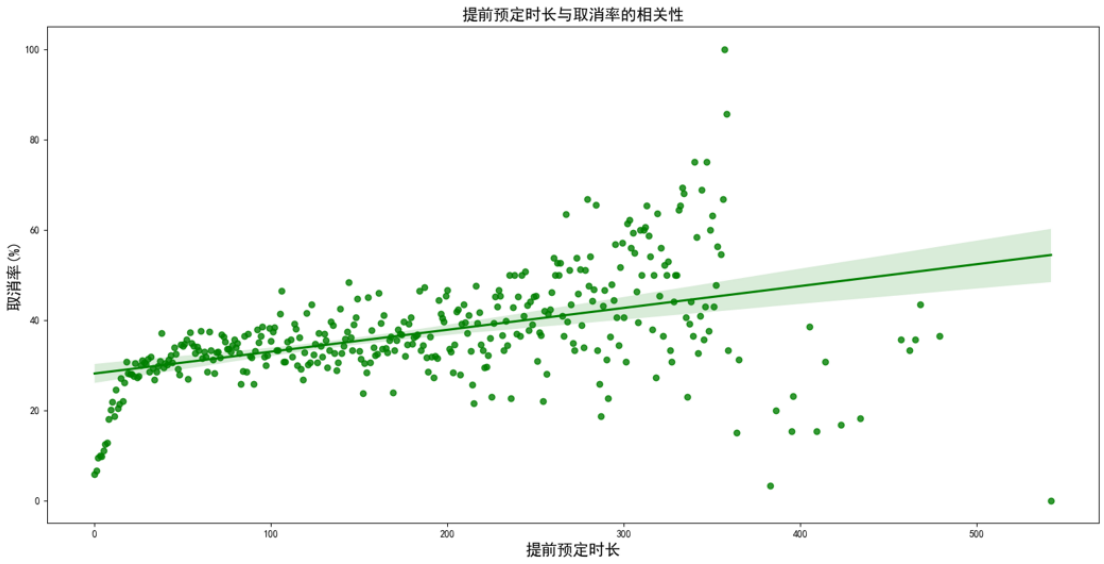

由散点图和拟合的回归线可以看出，顾客提前预定的时间越长，计划改变的概率越高。

3.2.5.4 平均每日房价

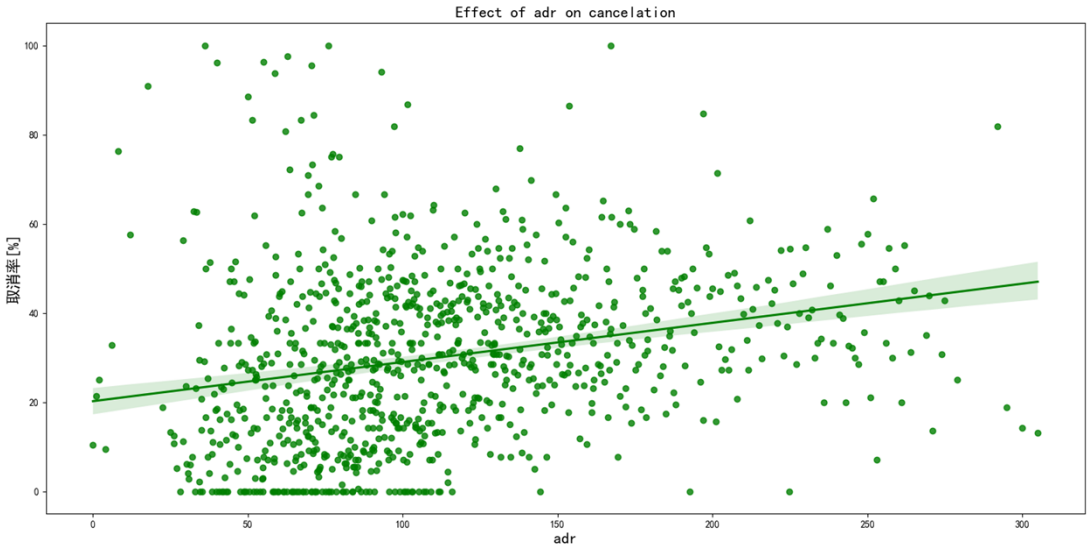

每日房价越低，开支越小，取消订单的代价越小，取消率也越高。

3.2.5.5 房型匹配率

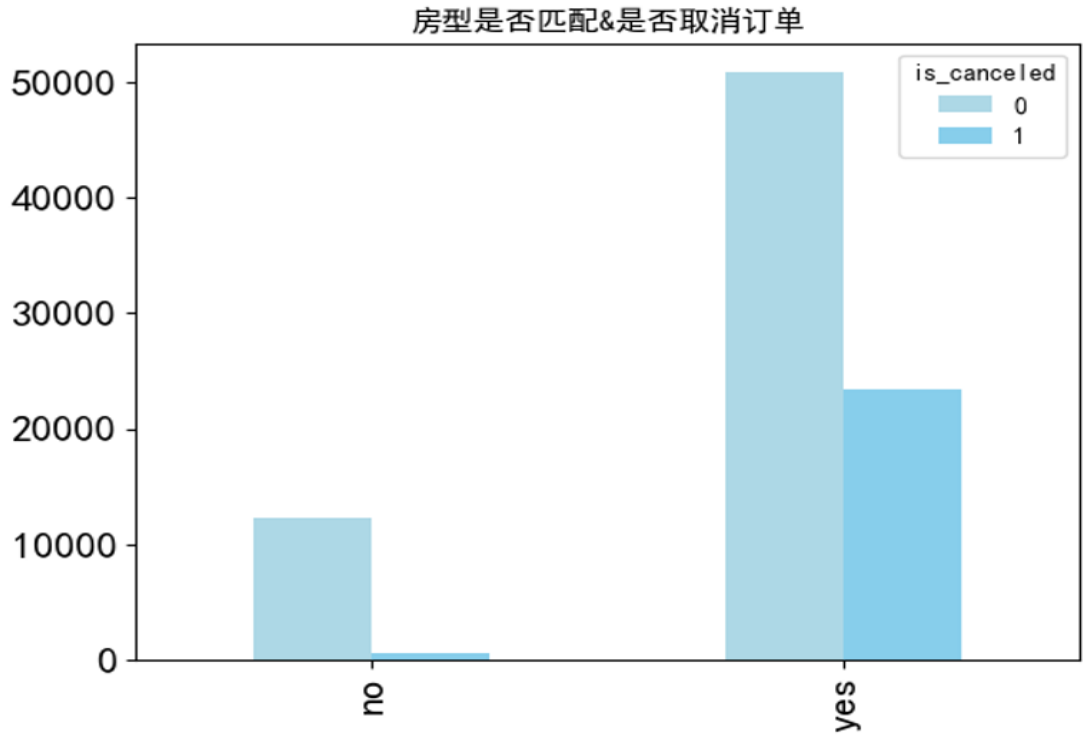

数据集中有 reserved_room_type 和 assigned_room_type 两个特征，即用户下单时选择的房型和届时入住的房型有可能不一样，但是研究结果显示：房型不匹配的用户反而不倾向于取消订单。对此猜测的原因可能有：1、房型不一致

属于酒店方房型升级的结果。2、因旺季酒店房源供不应求所以大众倾向于妥协。

3.2.6 相关性分析

查看每一个特征与 is_canceled 的相关系数

```
Name: is_canceled, dtype: float64
is_canceled                     1.000000
lead_time                       0.292876
total_of_special_requests       0.234877
required_car_parking_spaces     0.195701
booking_changes                 0.144832
previous_cancellations          0.110139
is_repeated_guest               0.083745
adults                          0.058182
previous_bookings_not_canceled  0.057365
days_in_waiting_list            0.054301
agent                           0.046770
adr                             0.046492
babies                          0.032569
stays_in_week_nights            0.025542
arrival_date_year               0.016622
arrival_date_week_number        0.008315
arrival_date_day_of_month       0.005948
children                        0.004851
stays_in_weekend_nights         0.001323
Name: is_canceled, dtype: float64
```

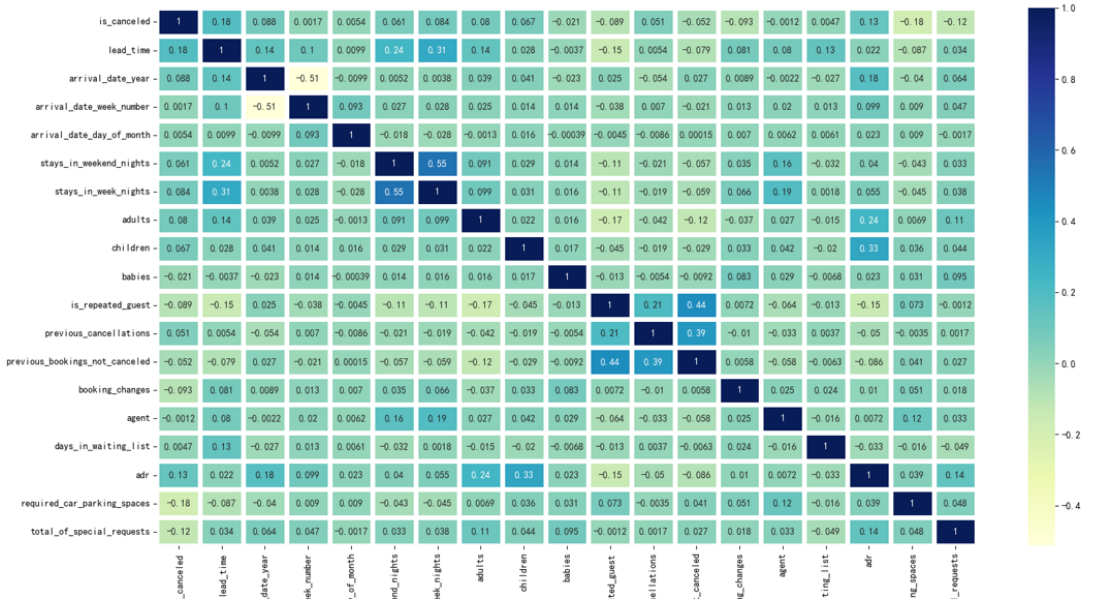

与是否取消订单相关性 top5 高的特征分别是：提前预定的时长、特殊要求总量、是否需要停车位、对预定进行的更改、历史取消量。

3.3 取消率预测

预测顾客是否会取消订单时我试用了六个机器学习的 base model，大体思路是将六个 base model 都尝试一遍，并选取表现最优的进行模型优化。我选取的 base 有：决策树、随机森林、逻辑回归、XGBoost、KNN 和 AdaBoost。

3.3.1 手动选取特征

此处删除所有时间类特征，arrival_date_year、arrival_date_month、arrival_date_week_number。

3.3.2 特征分类

```
#分离特征类型
num_features = ["lead_time","booking_changes","total_of_special_requests","required_car_parking_spaces",
                "days_in_waiting_list",
                 "previous_cancellations","is_repeated_guest","adults","previous_bookings_not_canceled","agent",
                "adr","babies","stays_in_weekend_nights","arrival_date_week_number","arrival_date_day_of_month",
                "children","stays_in_week_nights"]

cat_features = ["hotel","arrival_date_month","meal","market_segment","country","assigned_room_type",
                "distribution_channel","reserved_room_type","deposit_type","customer_type"]
#分离特征和预测值
features = num_features + cat_features
X = data_new.drop(["is_canceled"], axis=1)[features]
y = data_new["is_canceled"]
```

数据集中有整数型特征和分类型特征，为了方便特征预处理，将两种特征分离到 num_features 和 cat_features 中。

3.3.3 特征预处理

```
# 预处理数值特征:
#整数型特征
# 对于大多数数值型的特征，用0填充缺失值
num_transformer = SimpleImputer(strategy="constant",fill_value=0)

# 分类型特征的预处理:
cat_transformer = Pipeline(steps=[("imputer", SimpleImputer(strategy="constant", fill_value="Unknown")),
                                  ("onehot", OneHotEncoder(handle_unknown='ignore'))])
```

对于整数型特征，用对于最大多数特征都符合逻辑的 0 进行填充；对于分类型特征，用 OneHotEncoder 将其数字化，方便后续评分。

3.3.4 选取评估模型的统计方法

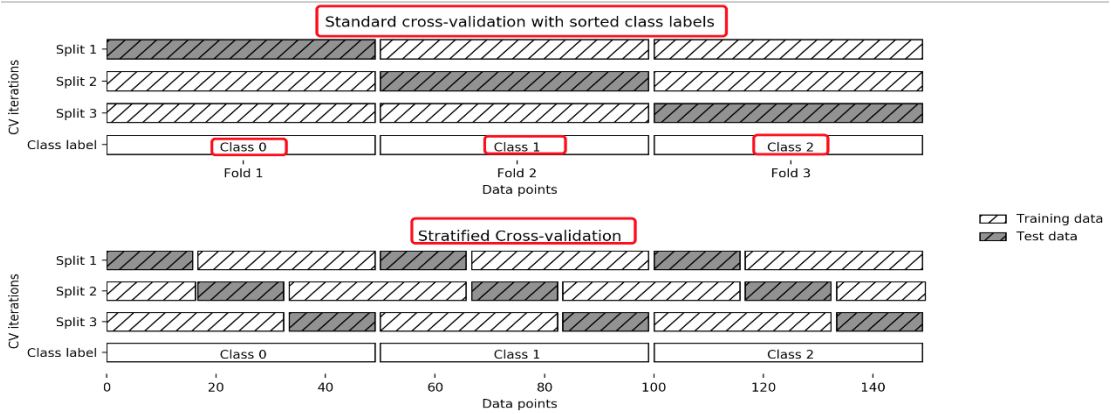

选取分层 K-Fold 交叉验证方法，其优点是对于不平衡的数据集比较友好，该方法可以将数据集先分成 k 折（实验中选择了十折，在用 train_test_split 函数划分模型的训练集和测试集时，通常会用四折，也就是 75%的数据作为训练集，25%的数据作为测试集；在五折交叉验证的时候，是 80%的数据作为训练集，20%的数据作为测试集；十折交叉验证的时候，是 90%的数据作为训练集，10%的数据作为测试集。显然，训练集的数据越多，模型的 accuracy 得分就越高。但是十折交叉运算也意味着六个模型都要训练十次，增加十倍的训练时间），然后再从每个 k 折中选择 k 折作为测试集合，这样就可以在口中程度上保证每次测试集合和训练集和都有各个类型的样本，特别是在当数据分类的类型数量相差悬殊的情况下，而本次实验所用的数据集有样本分布不均匀的问题，客户取消和未取消的比例约为 3:7，分层 k 折交叉验证可以使随机划分测试集时不存在一个测试集中全部都是未取消顾客的情况。缺点是在该方法中样本是随机选取的，所以不适合时间序列型数据，因此在手动选取特征值的阶段删去了所有时间型特征，一是为了让模型更加通用，不受限于 2015-2017 的时间范围，二是为了与评估方法更加适配。

3.3.5 模型评分展示

```
DT_model cross validation accuracy score: 0.8601 +/- 0.0027 (std) min: 0.8556, max: 0.8654,mean:0.8601
RF_model cross validation accuracy score: 0.8941 +/- 0.0023 (std) min: 0.8922, max: 0.9004,mean:0.8941
LR_model cross validation accuracy score: 0.8151 +/- 0.0023 (std) min: 0.8107, max: 0.8187,mean:0.8151
XGB_model cross validation accuracy score: 0.8772 +/- 0.0018 (std) min: 0.8739, max: 0.8794,mean:0.8772
KNN_model cross validation accuracy score: 0.8097 +/- 0.0035 (std) min: 0.8043, max: 0.8179,mean:0.8097
AdaB_model cross validation accuracy score: 0.8298 +/- 0.0034 (std) min: 0.8243, max: 0.8354,mean:0.8298
```

可以看出随机森林是表现最好的模型，XGBoost 次之，表现最差的是 KNN。对 KNN 表现不好的猜测：在样本不平衡的时候，对稀有类别的预测准确率低，比如一个类的样本容量很大，输入一个样本的时候，K 个临近值中大多数都是大样本容量的那个类。假设实验中取消订单的顾客占比大约百分之 30，即使 KNN 得分在 80 左右，也有可能把所有顾客都预测成了未取消订单的顾客；相比起决策树等模型，KNN 模型的可解释性也不强，是慵懒学习法，基本上不学习，导致实验时的运行速度相对于其他算法更慢。

对随机森林表现好的猜测：对多元共线性不敏感，对非平衡的数据比较稳健。通过 bootstrap 重采样技术，可以对占比高的样本降采样，也可以对占比少的样本过采样，以此弱化样本不平衡的问题。

4、 模型优化

选取表现最优的随机森林模型，并对其进行 n_estimators 参数调优。

```
rfc_s = []
for i in range(0, 181, 10):
    rf_model_enh = RandomForestClassifier(n_estimators=i,max_features=0.4,min_samples_split=2,random_state=42)
    split = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
    model_pipe = Pipeline(steps=[('preprocessor', preprocessor),('model', rf_model_enh)])
    cv_results = cross_val_score(model_pipe, X, y, cv=split,scoring="accuracy",n_jobs=-1)
    min_score = round(min(cv_results), 4)
    max_score = round(max(cv_results), 4)
    mean_score = round(np.mean(cv_results), 4)
    std_dev = round(np.std(cv_results), 4)
    print(f"Enhanced RF model cross validation accuracy score: {mean_score} +/- {std_dev} (std) min: {min_score}, max: {max_score}, mean:{mean_
    rfc_s.append(mean_score)
plt.plot(range(0,181,10),rfc_s,label='随机森林')
plt.legend()
```

将范围设置在 0-180 之间，步长为 10，并绘制学习曲线。

```
Enhanced RF model cross validation accuracy score: nan +/- nan (std) min: nan, max: nan, mean:nan, n_estimators: 0
Enhanced RF model cross validation accuracy score: 0.8862 +/- 0.0026 (std) min: 0.8827, max: 0.8903, mean:0.8862, n_estimators: 10
Enhanced RF model cross validation accuracy score: 0.8917 +/- 0.0021 (std) min: 0.8874, max: 0.8942, mean:0.8917, n_estimators: 20
Enhanced RF model cross validation accuracy score: 0.8931 +/- 0.0025 (std) min: 0.8894, max: 0.8961, mean:0.8931, n_estimators: 30
Enhanced RF model cross validation accuracy score: 0.8936 +/- 0.0027 (std) min: 0.889, max: 0.8978, mean:0.8936, n_estimators: 40
Enhanced RF model cross validation accuracy score: 0.8945 +/- 0.0023 (std) min: 0.8909, max: 0.898, mean:0.8945, n_estimators: 50
Enhanced RF model cross validation accuracy score: 0.895 +/- 0.0026 (std) min: 0.8914, max: 0.8988, mean:0.895, n_estimators: 60
Enhanced RF model cross validation accuracy score: 0.8949 +/- 0.0025 (std) min: 0.8916, max: 0.8986, mean:0.8949, n_estimators: 70
Enhanced RF model cross validation accuracy score: 0.8951 +/- 0.0024 (std) min: 0.8916, max: 0.8988, mean:0.8951, n_estimators: 80
Enhanced RF model cross validation accuracy score: 0.8955 +/- 0.0025 (std) min: 0.8913, max: 0.8993, mean:0.8955, n_estimators: 90
Enhanced RF model cross validation accuracy score: 0.8956 +/- 0.0024 (std) min: 0.8928, max: 0.9004, mean:0.8956, n_estimators: 100
Enhanced RF model cross validation accuracy score: 0.8957 +/- 0.0023 (std) min: 0.8925, max: 0.9004, mean:0.8957, n_estimators: 110
Enhanced RF model cross validation accuracy score: 0.896 +/- 0.0024 (std) min: 0.8925, max: 0.9003, mean:0.896, n_estimators: 120
Enhanced RF model cross validation accuracy score: 0.8959 +/- 0.0025 (std) min: 0.8927, max: 0.9006, mean:0.8959, n_estimators: 130
Enhanced RF model cross validation accuracy score: 0.8958 +/- 0.0023 (std) min: 0.893, max: 0.9, mean:0.8958, n_estimators: 140
Enhanced RF model cross validation accuracy score: 0.8956 +/- 0.0021 (std) min: 0.893, max: 0.8994, mean:0.8956, n_estimators: 150
Enhanced RF model cross validation accuracy score: 0.8956 +/- 0.0024 (std) min: 0.8927, max: 0.8998, mean:0.8956, n_estimators: 160
Enhanced RF model cross validation accuracy score: 0.8957 +/- 0.0023 (std) min: 0.893, max: 0.8994, mean:0.8957, n_estimators: 170
Enhanced RF model cross validation accuracy score: 0.8959 +/- 0.0022 (std) min: 0.893, max: 0.8999, mean:0.8959, n_estimators: 180
```

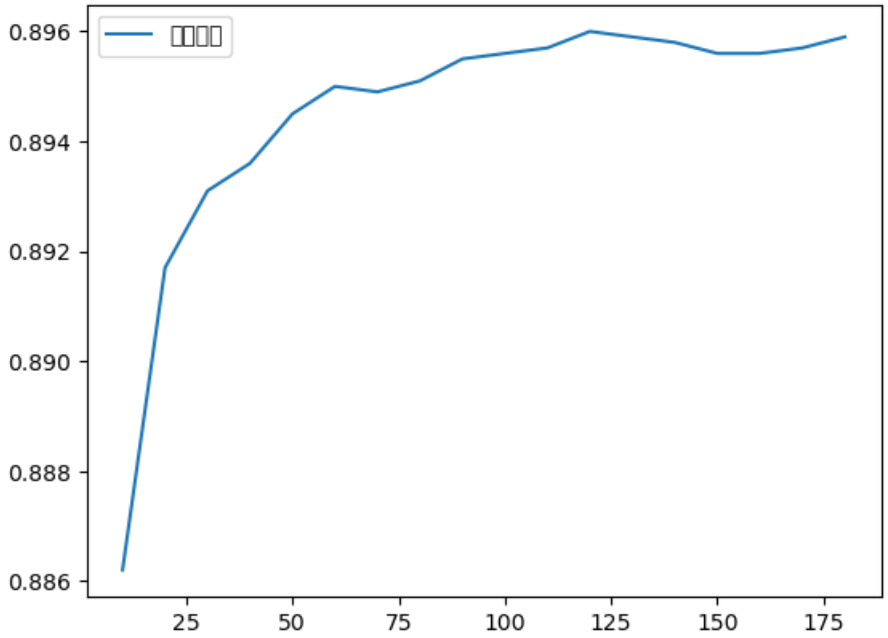

通过学习曲线可以看出：模型在 120 左右的参数区间内表现最好，于是可以根据该图缩小参数范围，本次实验尝试 118、119、121、122 这些参数，结果显示模型在 n_estimators=120 的时候表现最优。

```
rf_model_enh = RandomForestClassifier(n_estimators=118,max_features=0.4,min_samples_split=2,random_state=42)
split = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
model_pipe = Pipeline(steps=[('preprocessor', preprocessor),('model', rf_model_enh)])
cv_results = cross_val_score(model_pipe, X, y, cv=split,scoring="accuracy",n_jobs=-1)
min_score = round(min(cv_results), 4)
max_score = round(max(cv_results), 4)
mean_score = round(np.mean(cv_results), 4)
std_dev = round(np.std(cv_results), 4)
print(f"Enhanced RF model cross validation accuarcy score: {mean_score} +/- {std_dev} (std) min: {min_score}, max: {max_score}, mean:{mean_scor

print("119")
rf_model_enh = RandomForestClassifier(n_estimators=119,max_features=0.4,min_samples_split=2,random_state=42)
split = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
model_pipe = Pipeline(steps=[('preprocessor', preprocessor),('model', rf_model_enh)])
cv_results = cross_val_score(model_pipe, X, y, cv=split,scoring="accuracy",n_jobs=-1)
min_score = round(min(cv_results), 4)
max_score = round(max(cv_results), 4)
mean_score = round(np.mean(cv_results), 4)
std_dev = round(np.std(cv_results), 4)
print(f"Enhanced RF model cross validation accuarcy score: {mean_score} +/- {std_dev} (std) min: {min_score}, max: {max_score}, mean:{mean_scor

print("121")
rf_model_enh = RandomForestClassifier(n_estimators=121,max_features=0.4,min_samples_split=2,random_state=42)
split = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
model_pipe = Pipeline(steps=[('preprocessor', preprocessor),('model', rf_model_enh)])
cv_results = cross_val_score(model_pipe, X, y, cv=split,scoring="accuracy",n_jobs=-1)
min_score = round(min(cv_results), 4)
max_score = round(max(cv_results), 4)
mean_score = round(np.mean(cv_results), 4)
std_dev = round(np.std(cv_results), 4)
print(f"Enhanced RF model cross validation accuarcy score: {mean_score} +/- {std_dev} (std) min: {min_score}, max: {max_score}, mean:{mean_scor

print("122")
rf_model_enh = RandomForestClassifier(n_estimators=122,max_features=0.4,min_samples_split=2,random_state=42)
split = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
model_pipe = Pipeline(steps=[('preprocessor', preprocessor),('model', rf_model_enh)])
cv_results = cross_val_score(model_pipe, X, y, cv=split,scoring="accuracy",n_jobs=-1)
min_score = round(min(cv_results), 4)
max_score = round(max(cv_results), 4)
mean_score = round(np.mean(cv_results), 4)
std_dev = round(np.std(cv_results), 4)
print(f"Enhanced RF model cross validation accuarcy score: {mean_score} +/- {std_dev} (std) min: {min_score}, max: {max_score}, mean:{mean_scor
```

```
118
Enhanced RF model cross validation accuarcy score: 0.8959 +/- 0.0022 (std) min: 0.893, max: 0.9001, mean:0.8959
119
Enhanced RF model cross validation accuarcy score: 0.8959 +/- 0.0023 (std) min: 0.8924, max: 0.8998, mean:0.8959
121
Enhanced RF model cross validation accuarcy score: 0.8958 +/- 0.0023 (std) min: 0.8928, max: 0.8999, mean:0.8958
122
Enhanced RF model cross validation accuarcy score: 0.8959 +/- 0.0024 (std) min: 0.8929, max: 0.9, mean:0.8959
```

5、特征评分

```
#拟合模型，以便可以访问值：
model_pipe.fit(X,y)

#需要所有（编码）功能的名称。
#从一个热编码中获取列的名称：
onehot_columns = list(model_pipe.named_steps['preprocessor'].
                      named_transformers_['cat'].
                      named_steps['onehot'].
                      get_feature_names(input_features=cat_features))

#为完整列表添加num_功能。
#顺序必须与X的定义相同，其中num_特征是第一个：
feat_imp_list = num_features + onehot_columns

#显示10个最重要的功能，提供功能名称：
feat_imp_df = eli5.formatters.as_dataframe.explain_weights_df(
    model_pipe.named_steps['model'],
    feature_names=feat_imp_list)
print(feat_imp_df.head(10))
```

	feature	weight	std
0	lead_time	0.146739	0.014666
1	deposit_type_Non Refund	0.121359	0.107476
2	adr	0.100540	0.003240
3	deposit_type_No Deposit	0.083718	0.104972
4	country_PRT	0.065081	0.029661
5	agent	0.054212	0.011421
6	total_of_special_requests	0.050366	0.010703
7	stays_in_week_nights	0.040145	0.002162
8	market_segment_Online TA	0.036139	0.016091
9	previous_cancellations	0.027699	0.014852

可以看出权重最大的三个特征是提前预定的时长、押金类型（不退回）和人均价格。其中提前预定的时长和人均价格都在前文的探索性分析中被证明与是否取消订单高度相关。